

Санкт-Петербургский политехнический университет Петра
Великого Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №3
"Боксплот Тьюки и анализ выбросов"

Работу выполнил:

Шевцов Д.А.

Группа:

5030102/30202

Преподаватель:

Баженов А.Н.

Санкт-Петербург
2026

Оглавление

Формулировка задачи	3
Цели:	3
Задачи:	3
Теоретическая часть	3
Используемые распределения	3
Расчёт Доля аномальных значений (6)	3
Реализация	3
Результаты:	4
Нормальное распределение	4
Доля аномальных значений	4
Боксплоты Тьюки	5
Распределение Коши	5
Доля аномальных значений	5
Боксплоты Тьюки	5
Распределение Лапласа	5
Доля аномальных значений	5
Боксплоты Тьюки	6
Распределение Пуассона	6
Доля аномальных значений	6
Боксплоты Тьюки	7
Распределение равномерное	7
Доля аномальных значений	7
Боксплоты Тьюки	7
Обсуждение:	8
Вывод	8
Список литературы	8
Приложения	8

Формулировка задачи

Цели:

Изучение построения боксплота Тьюки и анализ влияния выборки на долю аномальных значений

Задачи:

- 1) Построение боксплота Тьюки
- 2) Изучение влияния выборки на боксплот Тьюки
- 3) Расчёт среднего для Доля аномальных значений при разных выборках
- 4) Оценка влияния выборки на долю аномальных значений

Теоретическая часть

Используемые распределения

- 1) Нормальное распределение

$$N(0,1); f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad (1)$$

- 2) Распределение Коши

$$C(0,1); f(x) = \frac{1}{\pi(1+x^2)} \quad (2)$$

- 3) Распределение Лапласа

$$L\left(0, \frac{1}{\sqrt{2}}\right); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|} \quad (3)$$

- 4) Распределение Пуассона

$$P(10); f(k) = \frac{10^k e^{-10}}{k!} \quad (4)$$

- 5) Равномерное распределение

$$U(-\sqrt{3}, \sqrt{3}); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases} \quad (5)$$

Расчёт Доля аномальных значений (6)

- 1) Подсчитываем квантили $z_{\frac{1}{4}}$ и $z_{\frac{3}{4}}$
- 2) Подсчитываем межквартильный размах IQR

$$IQR = z_{\frac{3}{4}} - z_{\frac{1}{4}}$$

- 3) Подсчитываем границы:

$$\text{Верхняя} = z_{\frac{3}{4}} + 1.5IQR$$

$$\text{Нижняя} = z_{\frac{1}{4}} - 1.5IQR$$

- 4) Все значения, которые не выходят в эти границы – аномальные значения
- 5) Считаем их количество и находим долю

Для доли считается выборочное среднее:

$$E(z) = \frac{1}{n} \sum_{i=1}^n z_i \quad (7)$$

Реализация

Используемый язык: Python 3.12.10

Используемая среда разработки: Visual Studio Code

Используемые библиотеки: numpy, matplotlib, scipy

В файле requirements.txt описаны все необходимые зависимости

Описание функций:

count_outliers(data) – функция подсчёта числа аномальных значений для выборки на основе

алгоритма (6). Вход: data – выборка. Выход: количество аномальных значений
 paint_distribution(name, data_list, sample_sizes) – функция отрисовки боксплотов Тьюки для выборок с помощью matplotlib. Вход: name – название распределения, data_list – массив состоящий из массивов данных для каждой выборки, sample_sizes – массив с размерами выборки соответствующими data_list. Пример графика:




Рис 1. Пример графика для функции paint_distribution

В функции main происходит вызов всех функций и обработка результатов, используемый seed для random = 5. Пример вывода данных:

```
Нормальное распределение:
Средняя доля выбросов для размера 20: 0.02
Средняя доля выбросов для размера 100: 0.01
```

Рис 2. Пример вывода в main

Результаты:

Нормальное распределение

Доля аномальных значений

```
Нормальное распределение:
Средняя доля выбросов для размера 20: 0.02
Средняя доля выбросов для размера 100: 0.01
```

Рис 3. Доля аномальных значений для нормального распределения

Нормальное распределение




Рис 4. Боксплоты Тьюки для нормального распределения

Распределение Коши

Доля аномальных значений

Коши распределение:
 Средняя доля выбросов для размера 20: 0.15
 Средняя доля выбросов для размера 100: 0.15

Рис 5. Доля аномальных значений для распределения Коши

Боксплоты Тьюки

Коши распределение




Рис 6. Боксплоты Тьюки для распределения Коши

Распределение Лапласа

Доля аномальных значений

Лапласа распределение:
Средняя доля выбросов для размера 20: 0.08
Средняя доля выбросов для размера 100: 0.07

Рис 7. Доля аномальных значений для распределения Лапласа

Боксплоты Тьюки




Рис 8. Боксплоты Тьюки для распределения Лапласа

Распределение Пуассона

Доля аномальных значений

Пуассона распределение:
Средняя доля выбросов для размера 20: 0.03
Средняя доля выбросов для размера 100: 0.01

Рис 9. Доля аномальных значений для распределения Пуассона

Боксплоты Тьюки

Figure 1

Пуассона распределение




Рис 10. Боксплоты Тьюки для распределения Пуассона

Распределение равномерное

Доля аномальных значений

Равномерное распределение:
Средняя доля выбросов для размера 20: 0.00
Средняя доля выбросов для размера 100: 0.00

Рис 11. Доля аномальных значений для равномерного распределения

Боксплоты Тьюки

Figure 1

Равномерное распределение




Рис 12. Боксплоты Тьюки для равномерного распределения

Обсуждение:

Боксплоты Тьюки – тип графиков, которые отражают характеристики выборки на одном графике. Красная полоса в боксплоте – медиана. Как видно медиана стремится к среднему, что соответствует результатам, полученным в прошлой работе. Границы прямоугольника – квартили, для $\frac{3}{4}$ - верхняя граница и $\frac{1}{4}$ - нижняя граница. Круглые точки – выбросы, алгоритм для определения выбросов была приведена выше (6). Усики – часть графика вне прямоугольника – точки, которые не попали в прямоугольник, но не считаются выбросами. По итогам работы можно сказать, что боксплоты – удобная форма представления данных, если необходимо узнать какие-то основные его характеристики (медиана и квартили) либо узнать примерную долю аномальных значений (количество точек на графике).

Анализируя результаты симуляций, можно прийти к таким результатам:

- 1) Равномерное распределение – не имеет выбросов при любом размере выбросов
- 2) Нормальное распределение и распределение Пуассона – доля выбросов сравнительно мала (< 0.05) и убывает с ростом числа значений в выборке
- 3) Распределение Лапласа – аналогично доля выбросов убывает с ростом числа значений в выборке, но она заметно выше по сравнению с двумя прошлыми распределениями
- 4) Распределение Коши – показывает наибольшую долю выбросов по сравнению со всеми распределениями, также по результатам было выяснено, что доля выбросов не убывает с ростом числа значений в выборке.

Вывод

По итогам лабораторной работы можно сделать следующие выводы:

- 1) Боксплот Тьюки – удобный и компактный способ представления данных, который, как и другие способы, необходимо использовать обоснованно. В случае уместного использования он позволяет легко видеть ключевые характеристики выборок
- 2) Изучение долей аномальных значений показал, что:

Равномерное распределение – не имеет выбросов, что связано с ограниченностью самого распределения.

Доли выбросов для нормального распределения и распределений Лапласа и Пуассона убывают с ростом числа значений в выборке, что связано с маленькими “хвостами” распределения.

Распределение Лапласа – доля выбросов не убывает с ростом значений в выборке.

По итогам можно сделать вывод, что существует связь между долей аномальных значений и скоростью убывания хвостов распределения.

Список литературы

Ширяев А. Н. Вероятность. Кн. 1. Элементарная теория вероятностей. Математические основания. Предельные теоремы / А. Н. Ширяев. — 4-е изд., перераб. и доп. — Москва : МЦНМО, 2007.
Boxplot, он же ящик с усами [Электронный ресурс] / Автор не указан // Хабр. — 2025. — 6 февр. — URL: <https://habr.com/ru/articles/879840/> (дата обращения: 16.02.2026).

Приложения

Репозиторий GitHub: https://github.com/Keendaj/MathStatLabs_2026/tree/Lab3