

Санкт-Петербургский политехнический университет Петра
Великого Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №6
"Линейная регрессия. Метод наименьших квадратов и
наименьших модулей"

Работу выполнил:

Шевцов Д.А.

Группа:

5030102/30202

Преподаватель:

Баженов А.Н.

Санкт-Петербург
2026

Оглавление

Формулировка задачи	3
Цели:	3
Задачи:	3
Теоретическая часть	3
Используемые распределения	3
Метод наименьших квадратов (МНК)	3
Метод наименьших модулей (МНМ)	3
Реализация	3
Результаты:	4
Чистая выборка	4
Значение рассчитанных коэффициентов	4
График регрессии	5
Выборка с выбросами	5
Значение рассчитанных коэффициентов	5
График регрессии	5
Обсуждение:	6
Вывод	6
Список литературы	6
Приложения	6

Формулировка задачи

Цели:

Сравнить метод наименьших квадратов (МНК) и метод наименьших модулей (МНМ)

Задачи:

- 1) Сгенерировать базовую выборку с линейной зависимостью и добавлением нормально распределенного шума.
- 2) Создать выборку с искусственно внесёнными выбросами.
- 3) Рассчитать регрессионные коэффициенты для данных выборок с помощью МНК и МНМ
- 4) Вычислить абсолютные и относительные погрешности оценок параметров для обоих методов и выборок.
- 5) Построить графики.

Теоретическая часть

Используемые распределения

- 1) Регрессионная зависимость:

$$y_i = a + bx_i + \varepsilon_i$$

- 2) Регрессионная зависимость с шумом:

$$y_i = a + bx_i + \varepsilon_i + 10 \cdot I(i),$$

Где $I(i) = 1_{\{i=0\}} - 1_{\{i=n-1\}}$

Метод наименьших квадратов (МНК)

Задача минимизировать целевую функцию за счёт изменения параметров a и b .

$$\sum_{i=1}^n (y_i - (a + bx_i))^2 \rightarrow \min (3)$$

Может быть решена аналитическим путём взятия производных и решения системы уравнений, пример решения:

$$b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}$$
$$a = \bar{y} - b\bar{x}$$

В программе используется библиотечная функция, которая более оптимизированно решает систему.

Метод наименьших модулей (МНМ)

Задача минимизировать целевую функцию за счёт изменения параметров a и b .

$$\sum_{i=1}^n |y_i - (a + bx_i)| \rightarrow \min (4)$$

Данная задача решается только численно, но возможно приближение коэффициентов с помощью результатов МНК, путём перехода к более робастным величинам.

$$b = r_{xy} \frac{\sqrt{D_y}}{\sqrt{D_x}}$$
$$a = \bar{y} - b\bar{x}$$

Реализация

Используемый язык: Python 3.12.10

Используемая среда разработки: Visual Studio Code

Используемые библиотеки: numpy, matplotlib, scipy

В файле requirements.txt описаны все необходимые зависимости

`mlm_objective(params, x, y)` — целевая функция (4). Вход: `params` — список подбираемых коэффициентов $[a, b]$, x, y — массивы значений переменных выборки.

`calculate_metrics(a_est, b_est, a_true, b_true)` — функция оценки качества полученных результатов. Рассчитывает абсолютную погрешность Δ и относительную погрешность δ в процентах для коэффициентов a и b относительно их истинных значений. Вход: a_est , b_est — вычисленные коэффициенты, a_true , b_true — теоретические значения параметров.

`fit_models(x, y)` — функция аппроксимации. Выполняет расчет параметров с помощью МНК и МНМ (в качестве начального приближения результаты МНК для скорости). Вход: x , y — массивы данных выборки.

`generate_base_data(size, a_true, b_true, seed)` — формирует выборку объемом 20 точек на интервале $[-1.8; 2.0]$. К значениям добавляется нормальный шум $N(0, 1)$. Вход: $size$ — объем выборки, a_true , b_true — параметры линейной зависимости, $seed$ — зерно генератора случайных чисел.

`create_outliers(y)` — модифицирует выборку. К первому элементу массива добавляется +10, от последнего отнимается 10. Вход: y — исходный массив значений зависимой переменной.

`print_table(title, models)` — формирует таблицу в консоли.

`plot_single_regression(x, y, models, title, is_outlier_plot)` — строит график регрессии. Вход: x , y — данные выборки, $models$ — рассчитанные параметры прямых, $title$ — заголовок графика, $is_outlier_plot$ — флаг визуального выделения выбросов.

Пример графика:




Рис 1. Пример графика для функции `plot_single_regression`.

Результаты:

Чистая выборка

Значение рассчитанных коэффициентов

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	1.962	0.038	1.891	2.165	0.165	8.226
МНМ	2.231	0.231	11.546	2.100	0.100	5.003

График регрессии




Рис 2. График регрессии для чистой выборки

Выборка с выбросами

Значение рассчитанных коэффициентов

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	2.105	0.105	5.252	0.736	1.264	63.203
МНМ	2.344	0.344	17.185	1.986	0.014	0.716

График регрессии




Рис 3. График регрессии для выборки с выбросами

Обсуждение:

МНК и МНМ:

Метод наименьших квадратов показал меньшую суммарную относительную погрешность для выборки без выбросов.

При добавлении выбросов метод наименьших модулей показал меньшую суммарную относительную погрешность.

Также можно заметить, что коэффициент a в МНМ вне зависимости от выборки считается с достаточно большой погрешностью. В МНК наоборот, коэффициент a практически не поменялся с добавлением выбросов и посчитан намного лучше в сравнении с МНМ.

График линейной регрессии:

Видно, что оба метода для выборки без выбросов построили схожие зависимости. Однако при добавлении выбросов МНК явно не смог определить зависимость и построил нечто сильно отличающееся от теории.

Вывод

По итогам выполненной лабораторной работы и анализа полученных результатов можно сделать следующие выводы:

- 1) На выборке без выбросов оба метода построили схожие регрессионные зависимости, подходящие теоретической модели. При этом МНК показал лучшую общую относительную погрешность 10.1%, в то время как МНМ имеет погрешность 16.55%, метод лучше использовать, если данные содержат только нормальный шум
- 2) При внесении в выборку грубых выбросов МНК показал чувствительность к ним. Прямая регрессии значительно отклонилась от теоретической. В то же время МНМ оказался робастным.
- 3) Коэффициент b - наиболее критичный параметр, определяющим характер зависимости. МНМ справляется с его поиском значительно лучше в условиях помех, погрешность составила 0.7% по сравнению с МНК и погрешностью в 63.2%.
- 4) Коэффициент a . Было замечено, что МНМ определяет данный параметр с более высокой погрешностью (11.55% и 17.19% для чистой и загрязнённой выборки соответственно) по сравнению с МНК (1.89% и 5.25% аналогично), вне зависимости от чистоты данных. МНК, наоборот, стабильно определял его, даже при наличии выбросов.

Список литературы

Ширяев А. Н. Вероятность. Кн. 1. Элементарная теория вероятностей. Математические основания. Предельные теоремы / А. Н. Ширяев. — 4-е изд., перераб. и доп. — Москва : МЦНМО, 2007.

Корреляция // Википедия. URL: <https://ru.wikipedia.org/wiki/Корреляция> (дата обращения: 12.03.2026).

Ядро (статистика) // Википедия. URL: [https://ru.wikipedia.org/wiki/Ядро_\(статистика\)](https://ru.wikipedia.org/wiki/Ядро_(статистика)) (дата обращения: 27.02.2026).

Бабахина С. А., Баженов А. Н. Практикум по математической статистике : учебное пособие. — Санкт-Петербург : СПбПУ, 2026.

Приложения

Репозиторий GitHub: https://github.com/Keendaj/MathStatLabs_2026/tree/Lab6