

Санкт-Петербургский политехнический университет Петра
Великого Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №3
"Боксплот Тьюки и анализ выбросов"

Работу выполнил:

Шевцов Д.А.

Группа:

5030102/30202

Преподаватель:

Баженов А.Н.

Санкт-Петербург
2026

Оглавление

Формулировка задачи	3
Цели:	3
Задачи:	3
Теоретическая часть	3
Используемые распределения	3
Расчёт Доля аномальных значений (6)	3
Реализация	3
Результаты:	4
Нормальное распределение	4
Доля аномальных значений	4
Боксплоты Тьюки	5
Распределение Коши	5
Доля аномальных значений	5
Боксплоты Тьюки	5
Распределение Лапласа	5
Доля аномальных значений	5
Боксплоты Тьюки	6
Распределение Пуассона	6
Доля аномальных значений	6
Боксплоты Тьюки	6
Распределение равномерное	7
Доля аномальных значений	7
Боксплоты Тьюки	7
Обсуждение:	7
Вывод	7
Список литературы	8
Приложения	8

Формулировка задачи

Цели:

Изучение построения боксплота Тьюки и анализ влияния выборки на долю аномальных значений

Задачи:

- 1) Построение боксплота Тьюки
- 2) Изучение влияния выборки на боксплот Тьюки
- 3) Расчёт среднего для Доля аномальных значений при разных выборках
- 4) Оценка влияния выборки на долю аномальных значений

Теоретическая часть

Используемые распределения

- 1) Нормальное распределение

$$N(0,1); f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad (1)$$

- 2) Распределение Коши

$$C(0,1); f(x) = \frac{1}{\pi(1+x^2)} \quad (2)$$

- 3) Распределение Лапласа

$$L\left(0, \frac{1}{\sqrt{2}}\right); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|} \quad (3)$$

- 4) Распределение Пуассона

$$P(10); f(k) = \frac{10^k e^{-10}}{k!} \quad (4)$$

- 5) Равномерное распределение

$$U(-\sqrt{3}, \sqrt{3}); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases} \quad (5)$$

Расчёт Доля аномальных значений (6)

- 1) Подсчитываем квантили $z_{\frac{1}{4}}$ и $z_{\frac{3}{4}}$
- 2) Подсчитываем межквартильный размах IQR

$$IQR = z_{\frac{3}{4}} - z_{\frac{1}{4}}$$

- 3) Подсчитываем границы:

$$\text{Верхняя} = z_{\frac{3}{4}} + 1.5IQR$$

$$\text{Нижняя} = z_{\frac{1}{4}} - 1.5IQR$$

- 4) Все значения, которые не выходят в эти границы – аномальные значения
- 5) Считаем их количество и находим долю

Для доли считается выборочное среднее:

$$E(z) = \frac{1}{n} \sum_{i=1}^n z_i \quad (7)$$

Реализация

Используемый язык: Python 3.12.10

Используемая среда разработки: Visual Studio Code

Используемые библиотеки: numpy, matplotlib, scipy

В файле requirements.txt описаны все необходимые зависимости

Описание функций:

count_outliers(data) – функция подсчёта числа аномальных значений для выборки на основе

алгоритма (6). Вход: data – выборка. Выход: количество аномальных значений
 paint_distribution(name, data_list, sample_sizes) – функция отрисовки боксплотов Тьюки для выборок с помощью matplotlib. Вход: name – название распределения, data_list – массив состоящий из массивов данных для каждой выборки, sample_sizes – массив с размерами выборки соответствующими data_list. Пример графика:




Рис 1. Пример графика для функции paint_distribution

В функции main происходит вызов всех функций и обработка результатов, используемый seed для random = 5. Пример вывода данных:

```
Нормальное распределение:
Средняя доля выбросов для размера 20: 0.02
Средняя доля выбросов для размера 100: 0.01
```

Рис 2. Пример вывода в main

Результаты:

Нормальное распределение

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.02
100	0.01

Рис 3. Доля аномальных значений для нормального распределения

Боксплоты Тьюки

Figure 1

Нормальное распределение




Рис 4. Боксплоты Тьюки для нормального распределения

Распределение Коши

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.15
100	0.15

Рис 5. Доля аномальных значений для распределения Коши

Боксплоты Тьюки

Figure 1

Коши распределение




Рис 6. Боксплоты Тьюки для распределения Коши

Распределение Лапласа

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.08

100	0.07
-----	------

Рис 7. Доля аномальных значений для распределения Лапласа

Боксплоты Тьюки

Figure 1

Лапласа распределение




Рис 8. Боксплоты Тьюки для распределения Лапласа

Распределение Пуассона

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.03
100	0.01

Рис 9. Доля аномальных значений для распределения Пуассона

Боксплоты Тьюки

Figure 1

Пуассона распределение




Рис 10. Боксплоты Тьюки для распределения Пуассона

Распределение равномерное

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.00
100	0.00

Рис 11. Доля аномальных значений для равномерного распределения

Боксплоты Тьюки




Рис 12. Боксплоты Тьюки для равномерного распределения

Обсуждение:

Боксплоты Тьюки – тип графиков, которые отражают характеристики выборки на одном графике. Красная полоса в боксплоте – медиана. Как видно медиана стремится к среднему, что соответствует результатам, полученным в прошлой работе. Границы прямоугольника – квартили, для $\frac{3}{4}$ - верхняя граница и $\frac{1}{4}$ - нижняя граница. Круглые точки – выбросы, алгоритм для определения выбросов была приведена выше (6). Усики – часть графика вне прямоугольника – точки, которые не попали в прямоугольник, но не считаются выбросами. По итогам работы можно сказать, что боксплоты – удобная форма представления данных, если необходимо узнать какие-то основные его характеристики (медиана и квартили) либо узнать примерную долю аномальных значений (количество точек на графике).

Анализируя результаты симуляций, можно прийти к таким результатам:

- 1) Равномерное распределение – не имеет выбросов при любом размере выбросов
- 2) Нормальное распределение и распределение Пуассона – доля выбросов сравнительно мала (< 0.05) и убывает с ростом числа значений в выборке
- 3) Распределение Лапласа – аналогично доля выбросов убывает с ростом числа значений в выборке, но она заметно выше по сравнению с двумя прошлыми распределениями
- 4) Распределение Коши – показывает наибольшую долю выбросов по сравнению со всеми распределениями, также по результатам было выяснено, что доля выбросов не убывает с ростом числа значений в выборке.

Вывод

По итогам лабораторной работы можно сделать следующие выводы:

1) Боксплот Тьюки – удобный и компактный способ представления данных, который, как и другие способы, необходимо использовать обоснованно. В случае уместного использования он позволяет легко видеть ключевые характеристики выборок

2) Изучение долей аномальных значений показал, что:

Равномерное распределение – не имеет выбросов, что связано с ограниченностью самого распределению.

Доли выбросов для нормального распределения и распределений Лапласа и Пуассона убывают с ростом числа значений в выборке, что связано с маленькими “хвостами” распределения.

Распределение Лапласа – доля выбросов не убывает с ростом значений в выборке.

По итогам можно сделать вывод, что существует связь между долей аномальных значений и скоростью убывания хвостов распределения.

Список литературы

Ширяев А. Н. Вероятность. Кн. 1. Элементарная теория вероятностей. Математические основания.

Предельные теоремы / А. Н. Ширяев. — 4-е изд., перераб. и доп. — Москва : МЦНМО, 2007.

Boxplot, он же ящик с усами [Электронный ресурс] / Автор не указан // Хабр. — 2025. — 6 февр. — URL: <https://habr.com/ru/articles/879840/> (дата обращения: 16.02.2026).

Приложения

Репозиторий GitHub: https://github.com/Keendaj/MathStatLabs_2026/tree/Lab3