

Санкт-Петербургский политехнический университет Петра
Великого Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №5
"Корреляционный анализ и
эллипсы рассеивания"

Работу выполнил:

Шевцов Д.А.

Группа:

5030102/30202

Преподаватель:

Баженов А.Н.

Санкт-Петербург
2026

Оглавление

Формулировка задачи	3
Цели:	3
Задачи:	3
Теоретическая часть	3
Используемые распределения	3
Расчёт коэффициентов корреляции	3
Реализация	4
Результаты:	4
Двумерное нормальное распределение	4
Значение рассчитанных коэффициентов.....	4
Эллипс рассеяния.....	5
Смесь распределений	6
Значение рассчитанных коэффициентов.....	6
Эллипс рассеяния.....	7
Обсуждение:	8
Вывод.....	8
Список литературы	9
Приложения	9

Формулировка задачи

Цели:

Сравнить исходное значение коэффициента корреляции с вычисленными на практике.
Изучить способы визуализации ковариационных данных.

Задачи:

- 1) Сгенерировать двумерные выборки из двумерного нормального распределения и смеси распределений.
- 2) Для каждой выборки вычислить коэффициенты корреляции Пирсона, Спирмена и квадрантный.
- 3) Повторить вычисления 1000 раз, найти средние значения и дисперсии для каждого коэффициента.
- 4) Построить эллипсы равновероятности для визуализации.

Теоретическая часть

Используемые распределения

- 1) Двумерное нормальное распределение

$$N(0,0,1,1,\rho) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right)$$

- 2) Смесь распределений

$$0.9 \cdot N(0,0,1,1,0.9) + 0.1 \cdot N(0,0,10,10,-0.9)$$

Расчёт коэффициентов корреляции

- 1) Коэффициент корреляции Пирсона (3)

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

- 2) Коэффициент ранговой корреляции Спирмена (4)

$$r_s = \frac{\sum_{i=1}^n (u_i - \bar{u})(v_i - \bar{v})}{\sqrt{\sum_{i=1}^n (u_i - \bar{u})^2 \sum_{i=1}^n (v_i - \bar{v})^2}},$$

где u_i и v_i — ранги i -ых элементов выборок, а $\bar{u}$ и $\bar{v}$ — средние значения рангов.

- 3) Квадрантный коэффициент корреляции (5)

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n},$$

где n_i — количество точек в i -ой квадранте.

- 4) Расчёт коэффициента корреляции для смеси распределений
Дисперсия симметрична для x и y , поэтому найдём общую:

$$D = 0.9^2 \cdot D_1 + 0.1^2 \cdot D_2 = 0.91$$

Коэффициент ковариации:

$$\text{cov}(X, Y) = 0.9^2 \cdot 0.9 + 0.1^2 \cdot (-0.9) \cdot \sqrt{10} \cdot \sqrt{10} = 0.639$$

Коэффициент корреляции:

$$r_{xy} = \frac{\text{cov}(X, Y)}{\sqrt{D_X} \sqrt{D_Y}} = \frac{0.639}{\sqrt{0.91} \cdot \sqrt{0.91}} \approx 0.702$$

Реализация

Используемый язык: Python 3.12.10

Используемая среда разработки: Visual Studio Code

Используемые библиотеки: numpy, matplotlib, scipy

В файле requirements.txt описаны все необходимые зависимости

`calc_quadratic_correlation(x, y)` – функция вычисления квадратного коэффициента корреляции по формуле (5). Вход: x , y – массивы значений переменных двумерной выборки. Выход: вычисленное значение квадратного коэффициента корреляции.

`Plot_subplots_ellipses(size, min_vals, max_vals, rho_keys, title_prefix, n_std)` – функция построения эллипсов рассеяния на отдельных координатных осях в рамках одного общего рисунка с помощью matplotlib. Вход: `size` – объем выборки, `min_vals` и `max_vals` – словари с границами сгенерированных данных, `rho_keys` – список значений коэффициентов корреляции для отображения, `title_prefix` – общий заголовок рисунка, `n_std` – количество стандартных отклонений, определяющее размер эллипса (по умолчанию 3.0). Выход: график эллипса рассеяния. Пример графика:




Рис 1. Пример графика для функции `plot_subplots_ellipses`.

Результаты:

Двумерное нормальное распределение

Значение рассчитанных коэффициентов

Коэффициент Пирсона

n	$\bar{r}_{xy}(\rho = 0)$	$D(\rho = 0)$	$\bar{r}_{xy}(\rho = 0.5)$	$D(\rho = 0.5)$	$\bar{r}_{xy}(\rho = 0.9)$	$D(\rho = 0.9)$
20	0.015	0.053	0.500	0.032	0.895	0.002
60	-0.002	0.017	0.498	0.010	0.899	0.001
100	-0.001	0.010	0.491	0.006	0.899	0.000

Коэффициент Спирмена

n	$\bar{r}_s(\rho = 0)$	$D(\rho = 0)$	$\bar{r}_s(\rho = 0.5)$	$D(\rho = 0.5)$	$\bar{r}_s(\rho = 0.9)$	$D(\rho = 0.9)$
20	0.013	0.053	0.470	0.037	0.865	0.005
60	-0.000	0.016	0.476	0.010	0.883	0.001
100	-0.002	0.010	0.472	0.007	0.887	0.001

Квадратный коэффициент

n	$\bar{r}_Q(\rho = 0)$	$D(\rho = 0)$	$\bar{r}_Q(\rho = 0.5)$	$D(\rho = 0.5)$	$\bar{r}_Q(\rho = 0.9)$	$D(\rho = 0.9)$
20	0.015	0.052	0.328	0.052	0.696	0.028
60	0.006	0.017	0.330	0.015	0.707	0.009
100	-0.000	0.010	0.325	0.009	0.710	0.005

Эллипс рассеяния

Размер выборки: 20




Рис 2. Эллипс рассеяния для двумерного нормального распределения при размере выборки 20

Размер выборки: 60




Рис 3. Эллипс рассеяния для двумерного нормального распределения при размере выборки 60

Размер выборки: 100




Рис 4. Эллипс рассеяния для двумерного нормального распределения при размере выборки 100

Смесь распределений

Значение рассчитанных коэффициентов

Коэффициент Пирсона

n	$\overline{r_{xy}}$	D
20	0.698	0.016
60	0.700	0.005
100	0.703	0.003

Коэффициент Спирмена

n	$\overline{r_s}$	D
20	0.668	0.019
60	0.678	0.006
100	0.682	0.004

Квадратный коэффициент

n	$\overline{r_Q}$	D
20	0.496	0.036
60	0.496	0.012
100	0.492	0.008

Эллипс рассеяния

Размер выборки: 20




Рис 5. Эллипс рассеяния для смеси распределений при размере выборки 20

Размер выборки: 60




Рис 6. Эллипс рассеяния для смеси распределений при размере выборки 60




Рис 7. Эллипс рассеяния для смеси распределений при размере выборки 100

Обсуждение:

Коэффициенты корреляции:

Было замечено, что с ростом числа элементов в выборке дисперсиях всех коэффициентов уменьшалась для всех распределений.

Двумерное нормальное распределение:

Наилучшее приближение к теоретическому коэффициенту корреляции показал коэффициент Пирсона. Худшее - квадратный коэффициент.

Смесь распределений:

Все коэффициенты "пострадали" от добавления 10% от другой выборки. И упали примерно на 0.2 пункта по сравнению с чистой выборкой.

Эллипс рассеяния

Двумерное нормальное распределение:

Для выборок $n = 20, 100$, заметно, что при увеличении ρ одна из осей эллипса стремится к прямой $y = x$, а также эллипс "сплющивается" к ней отходя от формы круга, что показывает зависимость координат между собой.

Для выборки $n = 60$, при $\rho = 0.5$ появилась аномалия в данных из-за чего эллипс наклонился в противоположную сторону, однако при $\rho = 0.9$ эта аномалия не наблюдается, можно назвать это погрешностью.

Смесь распределений:

Из-за выбросов при разных размерах выборки эллипсы уменьшают свою "приплюснутость", а также увеличивают наклон эллипса (одна из осей стремится к $y = x$).

Вывод

По итогам выполненной лабораторной работы и анализа полученных результатов можно сделать следующие выводы:

1. Подтверждено, что с увеличением объема выборки (n) дисперсия всех исследуемых коэффициентов корреляции уменьшается. То есть оценки сходятся с увеличением выборки.
2. Для двумерного нормального распределения наиболее точным является коэффициент Пирсона с дисперсией. Квадрантный коэффициент показывает наихудшее численное приближение к исходному параметру.
3. Анализ смеси распределений показал, что 10% данных с высокой дисперсией и обратным коэффициентом корреляции существенно искажает картину. Все три коэффициента показали падение значений (в среднем на 0.2 пункта), что соответствует теоретическому значению. При этом лучше всего себя показал коэффициент Пирсона, имея наименьшую дисперсию на всех выборках – 0.016, 0.005, 0.03.
4. Установлено, что при увеличении положительной корреляции эллипс закономерно «сплющивается» и вытягивается вдоль прямой $y = x$, что визуально подтверждает наличие линейной зависимости между координатами.
5. Визуальный анализ подтвердил высокую чувствительность к выбросам. Случайные погрешности генерации (как в случае $n = 60$, $\rho = 0.5$) способны изменить наклон эллипса. В случае смешанного распределения наличие выбросов приводит к потере «сплюснутости» эллипса и искажению его ориентации относительно прямой $y = x$, что не даёт определить исходную зависимость.

Список литературы

Ширяев А. Н. Вероятность. Кн. 1. Элементарная теория вероятностей. Математические основания. Предельные теоремы / А. Н. Ширяев. — 4-е изд., перераб. и доп. — Москва : МЦНМО, 2007.

Корреляция // Википедия. URL: <https://ru.wikipedia.org/wiki/Корреляция> (дата обращения: 12.03.2026).

Ядро (статистика) // Википедия. URL: [https://ru.wikipedia.org/wiki/Ядро_\(статистика\)](https://ru.wikipedia.org/wiki/Ядро_(статистика)) (дата обращения: 27.02.2026).

Бабахина С. А., Баженов А. Н. Практикум по математической статистике : учебное пособие. — Санкт-Петербург : СПбПУ, 2026.

Приложения

Репозиторий GitHub: https://github.com/Keendaj/MathStatLabs_2026/tree/Lab5