

Санкт-Петербургский политехнический университет Петра
Великого Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №1,2
"Гистограммы и характеристики распределений"

Работу выполнил:

Шевцов Д.А.

Группа:

5030102/30202

Преподаватель:

Баженов А.Н.

Оглавление

Формулировка задачи	3
Цели:	3
Задачи:	3
Теоретическая часть	3
Используемые распределения	3
Используемые характеристики	3
Реализация	3
Результаты:	5
Нормальное распределение	5
Характеристики	5
Гистограммы	5
Распределение Коши	5
Характеристики	5
Гистограммы	5
Распределение Лапласа	6
Характеристики	6
Гистограммы	6
Распределение Пуассона	7
Характеристики	7
Гистограммы	7
Распределение равномерное	7
Характеристики	7
Гистограммы	8
Обсуждение:	8
Вывод	9
Список литературы	9
Приложения	9

Формулировка задачи

Цели:

Изучение построения гистограмм и характеристик распределения на основе разных выборок

Задачи:

- 1) Освоить принцип группировки данных и построения гистограмм
- 2) Изучение влияния размера выборки на определение характера распределения
- 3) Исследование сходимости характеристик к теоретическим при росте числа элементов в выборке
- 4) Оценка характеристик положения на устойчивость к выбросам

Теоретическая часть

Используемые распределения

- 1) Нормальное распределение

$$N(0,1); f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad (1)$$

- 2) Распределение Коши

$$C(0,1); f(x) = \frac{1}{\pi(1+x^2)} \quad (2)$$

- 3) Распределение Лапласа

$$L\left(0, \frac{1}{\sqrt{2}}\right); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|} \quad (3)$$

- 4) Распределение Пуассона

$$P(10); f(k) = \frac{10^k e^{-10}}{k!} \quad (4)$$

- 5) Равномерное распределение

$$U(-\sqrt{3}, \sqrt{3}); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases} \quad (5)$$

Используемые характеристики

- 1) Выборочное среднее

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (6)$$

- 2) Медиана – квантиль $z_{\frac{1}{2}}$ (7)

- 3) Полусумма экстремальных элементов

$$z_R = \frac{x_{min} + x_{max}}{2} \quad (8)$$

- 4) Полусумма квартилей

$$z_Q = \frac{z_{\frac{1}{4}} + z_{\frac{3}{4}}}{2} \quad (9)$$

- 5) Усечённое среднее z_{tr} (10), расчёт как у выборочного среднего, но отбрасываются 10% наибольших и наименьших значений

Для характеристик считаются среднее и дисперсия:

$$E(z) = \bar{z} \quad (11)$$

$$D(z) = \overline{z^2} - (\bar{z})^2 \quad (12)$$

Для записи характеристик будем использоваться запись вида

$$E(z) \pm \sqrt{D(z)}$$

Реализация

Используемый язык: Python 3.12.10

Используемая среда разработки: Visual Studio Code

Используемые библиотеки: numpy, matplotlib, scipy

В файле requirements.txt описаны все необходимые зависимости

Описание функций:

`calculate_bins(data)` – функция подсчёта размера одного интервала на основе квантилей $\frac{1}{4}$ и $\frac{3}{4}$ (формула Фридмана-Диакониса). Вход: `data` - выборка значений

`get_theoretical(name, x_range)` – функция получения теоретических распределений для (1) – (5), для подсчёта используются библиотечные функции. Вход: `name` – название распределения, `x_range` – сетка аргументов, для которых нужно получить значения.

`paint_distribution(name, data_list, sample_sizes)` – функция отрисовки графиков экспериментального распределения и теоретического распределения с помощью `matplotlib`. Вход: `name` – название распределения, `data_list` – массив состоящий из массивов данных для каждой выборки, `sample_sizes` – массив с размерами выборки соответствующими `data_list`. Пример графика:




Рис 1. Пример графика для функции `paint_distribution`

`calculate_characteristics(data)` – функция подсчёта характеристик распределения (6)-(10), для подсчёта используются библиотечные функции. Вход: `data` – выборка

`print_results_table(dist_name, results, size)` – функция печати результатов подсчёта среднего (11) и дисперсии (12) всех характеристик для разных выборок. Вход: `dist_name` – название распределения, `results` – словарь с результатами для каждой характеристики, `size` – размер выборки. Пример вывода:

Нормальное РАСПРЕДЕЛЕНИЕ (n = 10)			
Оценка	Среднее	Дисперсия	<x> +- D
mean	-0.000024	0.104776	-0.0 +- 0.1
median	-0.005193	0.155193	-0.0 +- 0.2
zR	0.008562	0.177655	0.0 +- 0.2
zQ	-0.004104	0.119268	-0.0 +- 0.1
ztr	-0.002170	0.112468	-0.0 +- 0.1

Рис 2. Пример вывода для функции `print_results_table`

Mean – выборочное среднее, остальное как в формулах (7)-(10)

В функции `main` происходит вызов всех функций и обработка результатов, используемый `seed` для `random = 5`

Результаты:

Нормальное распределение

Характеристики

Характеристика	Нормальное (n=10)	Нормальное (n=100)	Нормальное (n=1000)
Выборочное среднее	0.0±0.3	0.0±0.1	0.0±0.0
Медиана	0.0±0.4	-0.0±0.1	0.0±0.0
ZR	0.0±0.4	0.0±0.3	-0.0±0.3
ZQ	0.0±0.3	0.0±0.1	0.0±0.0
Ztr	0.0±0.3	-0.0±0.1	0.0±0.0

Рис 3. Данные характеристик для нормального распределения

Гистограммы




Рис 4. Гистограммы для нормального распределения

Распределение Коши

Характеристики

Характеристика	Коши (n=10)	Коши (n=100)	Коши (n=1000)
Выборочное среднее	0.0±17.1	-43.0±1448.1	25.1±959.4
Медиана	0.0±0.6	-0.0±0.2	0.0±0.1
ZR	-0.1±82.8	-2148.3±72402.1	12538.2±479719.0
ZQ	0.1±0.9	-0.0±0.2	0.0±0.1
Ztr	0.0±2.5	-0.0±0.2	0.0±0.1

Рис 5. Данные характеристик для распределения Коши

Гистограммы

Для гистограммы распределения Коши была запущена отдельная итерация с seed = 4.

Коши распределение




Рис 6. Гистограммы для распределения Коши

Распределение Лапласа

Характеристики

Характеристика	Лапласа (n=10)	Лапласа (n=100)	Лапласа (n=1000)
Выборочное среднее	-0.0±0.3	0.0±0.1	0.0±0.0
Медиана	-0.0±0.3	-0.0±0.1	0.0±0.0
ZR	-0.0±0.6	-0.0±0.6	-0.0±0.6
ZQ	-0.0±0.3	0.0±0.1	0.0±0.0
Ztr	-0.0±0.3	0.0±0.1	0.0±0.0

Рис 7. Данные характеристик для распределения Лапласа

Гистограммы

Лапласа распределение




Рис 8. Гистограммы для распределения Лапласа

Распределение Пуассона

Характеристики

Характеристика	Пуассона (n=10)	Пуассона (n=100)	Пуассона (n=1000)
Выборочное среднее	10.0±1.0	10.0±0.3	10.0±0.1
Медиана	9.8±1.2	9.9±0.5	10.0±0.1
ZR	10.2±1.4	11.0±1.0	11.7±0.8
ZQ	9.9±1.0	9.9±0.4	10.0±0.1
Ztr	9.9±1.0	9.9±0.3	9.9±0.1

Рис 9. Данные характеристик для распределения Пуассона

Гистограммы




Рис 10. Гистограммы для распределения Пуассона

Распределение равномерное

Характеристики

Характеристика	Равномерное (n=10)	Равномерное (n=100)	Равномерное (n=1000)
Выборочное среднее	0.0±0.3	-0.0±0.1	-0.0±0.0
Медиана	0.0±0.5	-0.0±0.2	0.0±0.1
ZR	0.0±0.2	-0.0±0.0	0.0±0.0
ZQ	0.0±0.4	-0.0±0.1	0.0±0.0
Ztr	0.0±0.4	-0.0±0.1	0.0±0.0

Рис 11. Данные характеристик для равномерного распределения




Рис 12. Гистограммы для равномерного распределения

Обсуждение:

Анализ гистограмм:

На всех графиках можно заметить, что с ростом выборки распределение приобретает явный вид. Так при $n = 10$ плотность вероятности имеет случайные значения и по гистограмме невозможно определить распределение (кроме случая равномерного распределения, по стечению обстоятельств при $n=10$ проще всего сказать, что оно равномерное).

А при $n=1000$ все графики стремятся к своему теоретическому распределению с хорошей точностью

Анализ характеристик:

Нормальное распределение – во всех характеристиках среднее равно 0.0, однако с ростом числа элементов в выборке дисперсия каждой характеристики уменьшается, хотя она и так была сравнительно мала. Каждая характеристика стремится к своему теоретическому значению. Лучше всего себя показывает выборочное среднее с наименьшей дисперсией при росте n . Усечённое среднее даёт чуть большую дисперсию по сравнению с обычным.

Распределение Коши – характеристики, а именно выборочное среднее и zR , имеют случайные среднее и дисперсию для каждой выборки, что соответствует теории, так как у распределения Коши нет среднего (интеграл расходится), а также оно имеет выбросы, из-за чего zR также искажается, так как очень чувствительно к выбросам. Однако усечённое среднее уже сходится к 0.0, так как все выбросы убираются. Среди остальных характеристик все стремятся к теоретическому значению 0.0, однако медиана показывает себя лучше всех, имея наименьшую дисперсию для каждой выборки.

Распределение Лапласа – все характеристики с ростом выборки сходятся к теоретическому среднему 0.0, наилучший результат сходимости дисперсии и среднего имеет медиана для всех выборок. Дисперсия zR вовсе не убывает с ростом выборки, что не позволяет её использовать. Усечённое среднее в данном случае имеет меньшую дисперсию по сравнению с выборочным средним.

Распределение Пуассона – zR с ростом n уходит от теоретического значения среднего, хотя дисперсия уменьшается. При малых выборках ($n = 10, 100$) лучше всего себя показывает подсчёт

выборочного среднего, с ростом n ($n = 1000$) дисперсия медианы и zQ становится явно меньше, чем дисперсии остальных характеристик. Лучше всего себя показывает zQ . Также с ростом n дисперсия выборочного и усечённого среднего практически не меняется. И усечённое среднее имеет большую дисперсию по сравнению с выборочным средним

Равномерное распределение – все характеристики стремятся к теоретическому среднему 0.0. Лучше всего себя показывает zR , её дисперсия уменьшается примерно в n^2 раз, дисперсия остальных характеристик примерно в n раз.

Вывод

В результате выполнения лабораторной работы были сделаны следующие выводы:

- 1) Было показано, что с увеличением числа элементов выборки все гистограммы распределений стремятся к графику теоретического распределения, то есть чем больше элементов, тем легче понять какое распределение представлено.
- 2) Все характеристики, кроме выборочного среднего и zR для Коши и zR для Пуассона, стремятся к своим теоретическим значениям среднего. Также среди них были выбраны наилучшие для каждого распределения:
 - a. Для нормального распределения лучшая характеристика – выборочное среднее
 - b. Для распределения Коши лучшая характеристика – медиана
 - c. Для распределения Лапласа лучшая характеристика - медиана
 - d. Для распределения Пуассона лучшая характеристика – при малых выборках выборочное среднее, при больших zQ (на основе квартилей $\frac{1}{4}$, $\frac{3}{4}$)
 - e. Для равномерного распределения лучшая характеристика – zR (ширина размаха)

Список литературы

Ширяев А. Н. Вероятность. Кн. 1. Элементарная теория вероятностей. Математические основания. Предельные теоремы / А. Н. Ширяев. — 4-е изд., перераб. и доп. — Москва : МЦНМО, 2007.

Приложения

Репозиторий GitHub: https://github.com/Keendaj/MathStatLabs_2026/tree/Lab1%2B2